

TEMA 1

Estadística descriptiva unidimensional

Com passar d'una llista de dades a una descripció clara del seu centre, dispersió i forma.

Què aprendrem?

- Identificar què és una variable, una observació i un conjunt de dades, i distingir tipus de variables.
- Ordenar i resumir dades mitjançant freqüències, taules i representacions gràfiques.
- Calcular i interpretar mitjana, mediana i moda com a mesures de centre.
- Mesurar la dispersió amb recorregut, variància, desviació típica, coeficient de variació i RIQ.
- Utilitzar quartils i boxplots per descriure posició i detectar possibles valors atípics.
- Escollir les mesures adequades segons la forma de la distribució i redactar una conclusió.

La pràctica seguirà exactament aquesta lògica: DADES → DISTRIBUCIÓ → CENTRE → EXTREMS → DISPERSIÓ → POSICIÓ → COMPARACIÓ → INFORME.

1. Què fa l'estadística descriptiva?

- L'estadística descriptiva organitza, resumeix i representa les dades que tenim davant.
- No intenta encara generalitzar de la mostra a tota una població: això correspon a la inferència estadística.
- “Unidimensional” significa que estudiem una sola variable cada vegada.
- Exemple: si registrem els minuts que 40 estudiants triguen a arribar al campus, la variable és “temps de desplaçament”.

Objectiu: substituir una llista difícil de llegir per una descripció que conservi la informació important.

2. Població, mostra, individu i variable

Conceptes

- Població: conjunt complet que ens interessa estudiar.
- Mostra: subconjunt de la població del qual tenim dades.
- Individu o unitat estadística: element sobre el qual observem informació.

En la pràctica

- Població possible: tots els estudiants del centre.
- Mostra: els 40 temps generats per al teu ID.
- Variable: temps de desplaçament fins al campus, mesurat en minuts.

3. Tipus de variables

Qualitatives

- Descriuen categories, no quantitats.
- Nominals: sense ordre natural (tipus de contracte, sector).
- Ordinals: amb ordre (satisfacció baixa, mitjana, alta).

Quantitatives

- Expressen una quantitat numèrica.
- Discretes: valors comptables, sovint enters (nombre de fills).
- Contínues: poden prendre qualsevol valor d'un interval (temps, salari, edat mesurada amb precisió).

4. Primer contacte amb les dades

- Abans de calcular res, convé mirar les observacions: quants valors hi ha? quin és el més petit? i el més gran?
- El nombre d'observacions s'indica habitualment amb n .
- Ordenar les dades de menor a major facilita trobar mediana, quartils i possibles valors extrems.
- El mínim i el màxim indiquen els límits observats, però no expliquen com es reparteixen els valors entre aquests extrems.

A la pràctica podràs alternar sempre entre dades brutes, dades ordenades i taula de freqüències.

5. Taula de freqüències: resum sense perdre el recompte

Exemple: nombre de dies d'absència en un mes per 20 treballadors.

x_i	f_i	$h_i = f_i/n$	F_i	H_i
0	5	0,25	5	0,25
1	7	0,35	12	0,60
2	4	0,20	16	0,80
3	3	0,15	19	0,95
4	1	0,05	20	1,00

f_i = freqüència absoluta · h_i = proporció del total · F_i = freqüència acumulada · H_i = proporció acumulada.

Exemple: $F_2=16$ significa que 16 dels 20 treballadors han faltat com a màxim 2 dies.

6. Dades individuals o dades agrupades?

- Quan hi ha pocs valors diferents, una taula de freqüències per valor és fàcil de llegir.
- Quan la variable és contínua o hi ha molts valors diferents, podem agrupar-los en intervals: 0–10, 10–20, 20–30...
- Agrupar simplifica la informació, però també en perd una mica: ja no veiem cada observació exacta.
- El nombre i amplada dels intervals poden modificar l'aspecte visual de l'histograma sense que les dades hagin canviat.

Els intervals són una decisió de representació; les observacions originals no canvien.

7. Tres maneres de presentar una distribució

- TIPUS 1 · Dades individuals: disposem de totes les observacions x_i , una per una.
- TIPUS 2 · Valors + freqüències: cada valor x_i apareix acompanyat de la seva freqüència n_i .
- TIPUS 3 · Intervals + freqüències: les observacions s'agrupen en classes i ja no coneixem cada valor exacte.
- El tipus de distribució NO canvia el fenomen estudiat; canvia la informació disponible i, per tant, la manera de calcular.

Abans d'aplicar una fórmula, identifica sempre si tens una distribució de tipus 1, 2 o 3.

8. Tipus 1 · Dades individuals

- Exemple: temps (min) = 10, 12, 12, 14, 17. $N = 5$ observacions.
- Mitjana: $\bar{X} = \sum x_i / N = (10+12+12+14+17)/5 = 13$ min.
- Mediana: ordenem les dades i prenem el valor central $\rightarrow 12$ min. Moda: el valor més repetit $\rightarrow 12$ min.
- Variància descriptiva: $\sigma^2 = \sum (x_i - \bar{X})^2 / N$. Treballem directament amb cada observació.

TIPUS 1: les fórmules utilitzen directament els valors individuals x_i .

9. Tipus 2 · Valors i freqüències

-
- Les mateixes dades es poden resumir així: 10→1 vegada; 12→2; 14→1; 17→1. $N = \sum n_i = 5$.
 - Mitjana: $\bar{X} = \sum (x_i \cdot n_i) / N = (10 \cdot 1 + 12 \cdot 2 + 14 \cdot 1 + 17 \cdot 1) / 5 = 13$ min.
 - Variància: $\sigma^2 = \sum [n_i (x_i - \bar{X})^2] / N$. Cada desviació pesa tantes vegades com indica n_i .
 - Mediana, moda i quartils es determinen tenint en compte les freqüències acumulades.

TIPUS 2: no perdem informació; només escrivim de forma compacta els valors repetits.

10. Tipus 3 · Dades agrupades en intervals

- Exemple: 0–10: 4 persones; 10–20: 10; 20–30: 6. Només coneixem l'interval de cada observació.
- Per calcular la mitjana utilitzem la marca de classe c_i , el punt mig: 5, 15 i 25.
- Mitjana aproximada: $\bar{X} \approx \Sigma(c_i \cdot n_i)/N$. La variància també substitueix x_i per c_i .
- Com que desconexem els valors exactes dins de cada interval, els estadístics calculats són aproximacions.

TIPUS 3: agrupem per simplificar, però a canvi perdem precisió.

11. Què canvia en les fórmules?

- TIPUS 1 · Mitjana: $\bar{X} = \sum x_i / N$ · Variància: $\sigma^2 = \sum (x_i - \bar{X})^2 / N$.
- TIPUS 2 · Mitjana: $\bar{X} = \sum (x_i n_i) / N$ · Variància: $\sigma^2 = \sum [n_i (x_i - \bar{X})^2] / N$.
- TIPUS 3 · Mitjana: $\bar{X} \approx \sum (c_i n_i) / N$ · Variància: $\sigma^2 \approx \sum [n_i (c_i - \bar{X})^2] / N$.
- En tots els casos N és el nombre total d'observacions; en tipus 2 i 3, $N = \sum n_i$.

La idea és sempre la mateixa; el que canvia és com representem cada observació en el càlcul.

12. Mediana, moda i quartils segons el tipus

- TIPUS 1 · Ordenem les observacions i localitzem directament la posició de la mediana i dels quartils.
- TIPUS 2 · Utilitzem les freqüències acumulades per saber en quin valor cau cada posició. La moda és el x_i amb major n_i .
- TIPUS 3 · Localitzem l'interval que conté la posició buscada. Parlem de classe mediana, classe modal o classe del quartil.
- En dades agrupades es poden fer estimacions dins de l'interval, però en aquest curs prioritzarem entendre la lògica.

La freqüència acumulada permet recuperar la posició quan les dades ja no estan escrites una per una.

13. Un mateix fenomen, tres presentacions

- TIPUS 1 conserva totes les dades i és la forma més directa quan tenim les observacions originals.
- TIPUS 2 és equivalent al tipus 1 si els valors són exactes: resumeix repeticions sense perdre informació.
- TIPUS 3 és útil amb moltes dades o variables contínues, però substitueix cada interval per un valor representatiu.
- Per això dos càlculs poden donar resultats lleugerament diferents si un usa dades originals i l'altre dades agrupades.

Pregunta obligatòria abans de calcular: “Quin tipus de distribució tinc davant?”

14. Quin gràfic utilitzem?

Variables qualitatives o discretes

- Diagrama de barres: categories separades.
- L'alçada representa freqüència o percentatge.
- És útil per contractes, sectors, categories de satisfacció o recomptes discrets.

Variables quantitatives contínues


- Histograma: els valors s'agrupen en intervals contigus.
- Permet veure centre, dispersió, asimetria, modes i possibles extrems.
- Un diagrama de punts és molt útil quan la mostra no és massa gran.

15. Histograma: què hem de mirar?

- Centre: al voltant de quins valors es concentra la major part de les observacions?
- Dispersió: les dades estan molt juntes o ocupen un interval ampli?
- Forma: és aproximadament simètrica, asimètrica a la dreta, asimètrica a l'esquerra o presenta més d'un grup?
- Valors extrems: hi ha observacions clarament separades de la resta?
- No hem de descriure una distribució només amb una xifra: el gràfic aporta informació que la mitjana pot ocultar.


16. Formes habituals d'una distribució

Simètrica




centre equilibrat

Asimetria positiva




cua cap a valors alts

Asimetria negativa



cua cap a valors baixos

Bimodal



dos grups o pics

17. Mesures de centre: tres preguntes diferents

- Mitjana: quin seria el valor si repartíssim el total de manera igual entre totes les observacions?
- Mediana: quin és el valor que queda al centre quan ordenem les dades?
- Moda: quin valor o categoria apareix més vegades?
- No hi ha una mesura “millor” en totes les situacions. L'elecció depèn de les dades i del que volem explicar.

A la pràctica calcularàs mitjana, mediana i freqüència modal i després observaràs com reaccionen a un valor extrem.

18. Mitjana: càlcul complet

Temps de desplaçament (min): 10, 12, 13, 15 i 20.

- 1 Sumem totes les observacions: $10 + 12 + 13 + 15 + 20 = 70$.
- 2 Comptem les observacions: $n = 5$.
- 3 Dividim la suma pel nombre d'observacions: $\bar{x} = 70 / 5 = 14$ min.

RESULTAT · Mitjana = 14 min

Interpretació · La mitjana utilitza tots els valors. Si un d'ells canvia molt, la mitjana també pot canviar.

19. Mediana: càlcul complet

Dades ordenades: 10, 12, 13, 15 i 20 min.

- 1 Ja estan ordenades de menor a major.
- 2 Com que $n=5$ és imparell, busquem la posició central: $(5+1)/2 = 3$.
- 3 El tercer valor és 13.

RESULTAT · Mediana = 13 min

Interpretació · La meitat de les observacions queda a cada costat de la mediana. Si n és parell, fem la mitjana dels dos valors centrals.

20. Moda: càlcul complet

Dies d'absència: 0, 1, 1, 1, 2, 2, 3, 4.

- 1 Comptem quantes vegades apareix cada valor.
- 2 0 apareix 1 vegada; 1 apareix 3; 2 apareix 2; 3 i 4 apareixen 1 vegada.
- 3 El valor amb freqüència més alta és 1.

RESULTAT · Moda = 1 dia

Interpretació · Pot haver-hi una moda, més d'una o cap moda clara. La moda també és aplicable a variables qualitatives.

21. Un valor extrem pot canviar la història

Compareu A = 10, 12, 13, 15, 20 amb B = 10, 12, 13, 15, 100.

- 1 A: mitjana = 14 i mediana = 13.
- 2 B: mitjana = $(10+12+13+15+100)/5 = 30$.
- 3 B: la mediana continua sent 13 perquè el valor central ordenat no ha canviat.
- 4 La mitjana ha passat de 14 a 30; la mediana, de 13 a 13.

RESULTAT · La mitjana és molt més sensible al valor extrem

Interpretació · En distribucions asimètriques o amb valors extrems, la mediana pot representar millor el valor “típic”.

22. El centre no és suficient

- Dues distribucions poden tenir la mateixa mitjana i, tanmateix, ser molt diferents.
- Exemple A: 8, 9, 10, 11, 12. Exemple B: 0, 5, 10, 15, 20. Totes dues tenen mitjana 10.
- A està molt concentrada al voltant de 10; B està molt més dispersa.
- Per descriure bé una variable necessitem combinar mesures de centre i de dispersió.

La dispersió respon a la pregunta: quant s'allunyen les observacions les unes de les altres o del seu centre?

23. Recorregut

Dades: 8, 9, 10, 11 i 12.

- 1 Identifiquem el mínim: 8.
- 2 Identifiquem el màxim: 12.
- 3 Calculem màxim – mínim: $12 - 8 = 4$.

RESULTAT · Recorregut = 4

Interpretació · És molt fàcil de calcular, però només utilitza dues observacions i és molt sensible als extrems.

24. Variància: què està mesurant?

Exemple: 8, 9, 10, 11, 12. La mitjana és 10.

x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
8	-2	4
9	-1	1
10	0	0
11	1	1
12	2	4

1. Distància respecte de la mitjana

Restem 10 a cada observació. Les distàncies negatives i positives es compensarien.

2. Elevem al quadrat

Així totes les contribucions són positives: $4+1+0+1+4 = 10$.

3. Fem la mitjana

Variància descriptiva = $10/5 = 2 \text{ min}^2$. En aquesta pràctica dividirem per n .

25. Desviació típica: tornar a les unitats originals

A l'exemple anterior la variància és 2 min^2 .

- 1 La variància queda expressada en unitats al quadrat, cosa poc intuïtiva.
- 2 Fem l'arrel quadrada de la variància: $s = \sqrt{2} = 1,414\dots$
- 3 Arrodonim segons la precisió necessària: 1,41 min.

RESULTAT · Desviació típica $\approx 1,41 \text{ min}$

Interpretació · Una desviació típica més gran indica, en general, més dispersió. Té les mateixes unitats que la variable original.

26. Variància descriptiva o mostral?

- Hi ha dues fórmules habituals: dividir la suma de quadrats per n o dividir-la per $n-1$.
- Quan simplement descrivim el conjunt de dades que tenim, podem utilitzar la variància descriptiva dividint per n .
- Quan una mostra s'utilitza per estimar la variància d'una població, és habitual utilitzar $n-1$.
- En la Pràctica 1 utilitzarem explícitament la versió descriptiva: divisió per n . Cal ser coherents també a Excel.

No és una contradicció: són fórmules amb objectius diferents. Aquí estem fent estadística descriptiva.

27. Coeficient de variació (CV)

Empresa A: salari mitjà 2.000 €, desviació típica 200 €. Empresa B: salari mitjà 4.000 €, desviació típica 300 €.

- 1 $CV = \text{desviació típica} / \text{mitjana} \times 100.$
- 2 Empresa A: $CV = 200/2.000 \times 100 = 10\%.$
- 3 Empresa B: $CV = 300/4.000 \times 100 = 7,5\%.$
- 4 En euros B té més desviació ($300 > 200$), però relativament al seu nivell salarial és menys variable.

RESULTAT · CV(A)=10%; CV(B)=7,5%

Interpretació · El CV és útil per comparar dispersions relatives quan les mitjanes o escales són diferents. No té unitats.

28. Quartils: dividir les dades ordenades en quatre parts

- Q1 deixa aproximadament el 25% de les observacions per sota.
- Q2 és la mediana: deixa aproximadament el 50% per sota.
- Q3 deixa aproximadament el 75% per sota.
- En aquesta pràctica utilitzarem una regla concreta i transparent: Q1 és la mediana de la meitat inferior i Q3 la mediana de la meitat superior.
- Hi ha diferents convencions de càlcul de quartils en software; per això és important indicar el mètode utilitzat.

29. Quartils i RIQ: exemple complet

Dades ordenades: 6, 8, 9, 10, 12, 13, 15, 18.

- 1 $n=8$. La mediana és $(10+12)/2 = 11$.
- 2 Meitat inferior: 6, 8, 9, 10 $\rightarrow Q1=(8+9)/2=8,5$.
- 3 Meitat superior: 12, 13, 15, 18 $\rightarrow Q3=(13+15)/2=14$.
- 4 $RIQ = Q3 - Q1 = 14 - 8,5 = 5,5$.

RESULTAT · $Q1=8,5$; mediana=11; $Q3=14$; $RIQ=5,5$

Interpretació · El RIQ descriu l'amplada del 50% central de les dades i és poc sensible als valors extrems.

30. Detectar possibles valors atípics amb $1,5 \cdot \text{RIQ}$

Utilitzem $Q1=8,5$, $Q3=14$ i $\text{RIQ}=5,5$.


- 1 Llíndar inferior = $Q1 - 1,5 \cdot \text{RIQ} = 8,5 - 8,25 = 0,25$.
- 2 Llíndar superior = $Q3 + 1,5 \cdot \text{RIQ} = 14 + 8,25 = 22,25$.
- 3 Qualsevol observació $<0,25$ o $>22,25$ es marca com a potencialment atípica.
- 4 Si afegíssim el valor 30, quedaria per sobre de 22,25 i es marcaria com a atípic.

RESULTAT · Interval no atípic segons la regla: $[0,25; 22,25]$

Interpretació · “Atípic” no significa necessàriament “error”. Pot ser una observació real que cal investigar i interpretar.

31. Boxplot: una radiografia compacta

El diagrama de caixa resumeix posició, dispersió i possibles valors atípics.



Caixa: $Q1 \rightarrow Q3$ · línia interior: mediana · bigotis: valors no atípics més extrems · punts separats: possibles atípics.

32. Comparar dues distribucions

A = 8, 9, 10, 11, 12 · B = 0, 5, 10, 15, 20.

- 1 Calculem el centre: totes dues tenen mitjana 10 i mediana 10.
- 2 A: variància = 2; desviació típica $\approx 1,41$.
- 3 B: desviacions respecte de 10: $-10, -5, 0, 5, 10 \rightarrow$ quadrats sumen 250.
- 4 B: variància = $250/5 = 50$; desviació típica = $\sqrt{50} \approx 7,07$.

RESULTAT · Mateix centre, però B és molt més dispersa

Interpretació · Comparar només les mitjanes hauria ocultat la diferència principal entre les dues distribucions.

33. Quines mesures convé utilitzar?

Distribució aproximadament simètrica

- La mitjana sol descriure bé el centre.
- La desviació típica complementa la mitjana per descriure dispersió.
- Convé mirar igualment l'histograma i possibles valors extrems.

Asimetria o valors extrems

- La mediana és més robusta per descriure el centre.
- El RIQ és una dispersió robusta.
- Mitjana i desviació típica encara poden informar, però s'han d'interpretar amb precaució.

34. Excel: què necessitareu a la pràctica?

- Ordenar dades i construir una taula de freqüències a partir de les observacions.
- Calcular mitjana, mediana, variància descriptiva i desviació típica amb fórmules d'Excel.
- Calcular Q1, Q3 i RIQ mantenint el mateix criteri de quartils definit a la pràctica.
- Construir o interpretar histogrames i comparar dues distribucions.
- Comprovar sempre que la funció utilitzada correspon al càlcul que volem fer: especialment variància dividida per n o per $n-1$.

Excel fa els càlculs; l'objectiu del tema és entendre què està calculant i saber interpretar-ne el resultat.

35. La Pràctica 1: el recorregut complet

1 DADES

n, mínim, màxim, recorregut

2 DISTRIBUCIÓ

freqüències i histograma

3 CENTRE

mitjana, mediana, moda

4 VALOR EXTREM

robustesa

5 DISPERSIÓ

variància, s, CV

6 POSICIÓ

Q1, Q3, RIQ, boxplot

7 COMPARAR

mateix centre, dispersió
diferent

8 INFORME

centre + dispersió + forma

36. Exemple integrat: com descriure una distribució

Temps de desplaçament: 10, 11, 12, 12, 13, 14, 15, 15, 16, 42 min.

Forma Hi ha una cua cap a la dreta causada pel valor 42.

Centre Mitjana = 16,0 min; mediana = $(13+14)/2 = 13,5$ min.

Dispersió Recorregut = $42 - 10 = 32$ min. La dispersió queda molt influïda pel 42.

Elecció Per explicar el valor típic, la mediana és més representativa que la mitjana.

Conclusió La major part dels temps se situa entre 10 i 16 min, però hi ha una observació molt alta que desplaça la mitjana.

Una bona descripció no és una llista de fórmules: explica què revelen conjuntament centre, dispersió i forma.

37. Idees clau del tema

- Comença sempre mirant i ordenant les dades abans de calcular.
- La taula de freqüències i l'histograma mostren com es distribueixen les observacions.
- Mitjana, mediana i moda no són sinònims: resumeixen el centre de maneres diferents.
- La dispersió és imprescindible: recorregut, variància, desviació típica, CV i RIQ aporten informació diferent.
- Els valors extrems poden ser reals i poden afectar molt la mitjana i la desviació típica.
- Per descriure bé una distribució, combina centre + dispersió + forma i justifica les mesures escollides.

Això és exactament el que hauràs de posar en pràctica al laboratori de descriptiva unidimensional.