

Estadística descriptiva bidimensional

Descriure la relació entre dues variables: del núvol de punts a la correlació i la recta de regressió.


Objectiu

Aprendre a mirar dues variables conjuntament.

Mesurar direcció i intensitat de la relació.

Construir i interpretar una regressió lineal senzilla.

Predir amb prudència i recordar: correlació $\neq$ causalitat.



Una observació ara conté dos valors

Exemple laboral: hores de formació (X) i puntuació en una prova (Y) per a cada treballador.

Treballador	X: hores	Y: puntuació
A	2	55
B	4	60
C	5	68
D	7	74
E	8	80
F	10	86

La unitat és la parella (xi, yi)

No podem separar les dues columnes: cada X ha d'anar amb el seu Y.
La pregunta ja no és només «com és X?» o «com és Y?», sinó «com varien conjuntament?»

A la pràctica

Treballareu amb una mostra personalitzada i construïreu el diagrama de dispersió abans de calcular mesures de relació.

El diagrama de dispersió

Cada observació es representa amb un punt de coordenades (x_i, y_i) .



Què hem de mirar?

Direcció: positiva, negativa o sense patró clar.

Forma: aproximadament lineal o corba.

Intensitat: punts molt alineats o molt dispersos.

Valors extrems: algun punt s'allunya molt de la resta?

Positiva, negativa o sense relació lineal

La correlació lineal resumeix sobretot patrons que s'assemblen a una recta.

POSITIVA

Quan X augmenta, Y tendeix a augmentar.

Ex.: més hores de formació → puntuacions més altes.

NEGATIVA

Quan X augmenta, Y tendeix a disminuir.

Ex.: més absentisme → menor producció, si aquest patró apareix a les dades.

SENSE RELACIÓ LINEAL CLARA

Els punts no mostren una direcció lineal consistent.

Això no prova que no existeixi cap altra relació.

Important: un núvol corbat pot tenir una correlació lineal baixa i, tot i així, existir una relació clara entre X i Y.

Mesurar si X i Y es mouen en la mateixa direcció

En aquest tema utilitzem la covariància descriptiva del conjunt observat, dividint per N.

Fórmula

$$\text{cov}(X,Y) = \Sigma[(x_i - \bar{X})(y_i - \bar{Y})] / N$$

x_i, y_i : valors de l'observació i

$\bar{X}, \bar{Y}$: mitjanes de X i Y

N: nombre de parelles

Interpretació del signe

$\text{cov} > 0 \rightarrow$ tendeixen a moure's en el mateix sentit.

$\text{cov} < 0 \rightarrow$ tendeixen a moure's en sentits oposats.

$\text{cov} \approx 0 \rightarrow$ poca relació lineal.

La magnitud depèn de les unitats; per comparar intensitat és millor r.

Exemple resultat pas a pas

$\bar{x}$ = 6.00 hores · $\bar{y}$ = 70.50 punts.

xi	yi	xi- $\bar{x}$	yi- $\bar{y}$	producte
2	55	-4.00	-15.50	62.00
4	60	-2.00	-10.50	21.00
5	68	-1.00	-2.50	2.50
7	74	1.00	3.50	3.50
8	80	2.00	9.50	19.00
10	86	4.00	15.50	62.00
TOTAL				170.00

Càlcul

$\Sigma[(xi-\bar{x})(yi-\bar{y})] = 170.00$

$cov(X,Y) = 170.00 / 6 = 28.33$

És positiva: X i Y tendeixen a augmentar conjuntament.

Una mesura estandarditzada entre -1 i $+1$

El coeficient de correlació lineal de Pearson elimina les unitats de la covariància.

Fórmula

$$r = \text{cov}(X,Y) / (\sigma X \cdot \sigma Y)$$

σX : desviació típica de X

σY : desviació típica de Y

Sempre: $-1 \leq r \leq 1$

Lectura

$r > 0 \rightarrow$ relació lineal positiva.

$r < 0 \rightarrow$ relació lineal negativa.

$|r|$ proper a 1 $\rightarrow$ punts molt alineats.

r proper a 0 $\rightarrow$ poca relació lineal.

No memoritzis fronteres rígides del tipus «0,7 = fort». La interpretació depèn del context i del núvol de punts.

Exemple resolt amb les mateixes dades

Així connectem covariància, desviacions típiques i correlació.

1. Ja tenim


$$\text{cov}(X,Y) = 28.33$$

2. Dispersió

$$\begin{aligned}\sigma X &= 2.65 \\ \sigma Y &= 10.80\end{aligned}$$

3. Substituïm

$$r = 28.33 / (2.65 \cdot 10.80) = 0.992$$



Interpretació

r és positiu i molt proper a +1.

En aquestes dades, els punts segueixen molt de prop una tendència lineal creixent.

Això descriu associació; no demostra que X causi Y.

Completa la taula i calcula covariància i correlació

Context: hores de formació (X) i puntuació (Y). Utilitza la variància/desviació descriptiva dividint per N.

xi	yi	xi- $\bar{X}$	yi- $\bar{Y}$	producte
1	42			
2	46			
4	51			
6	59			
7	61			
TOTAL				

CALCULA

$\bar{X}$ = _____ $\bar{Y}$ = _____

cov(X,Y) = _____


σX = _____ σY = _____

r = _____

Interpreta el signe i la intensitat observada.

Un sol punt pot canviar molt r i la recta

Per això el diagrama de dispersió s'ha de mirar abans i després de calcular.



Què fem?

No eliminem un punt només perquè molesta.

Comprovem si és error o observació real.

Calculem/visualitzem amb i sense el punt per entendre la sensibilitat.

Expliquem qualsevol decisió en l'informe.

Resumir la relació amb una recta

La recta permet descriure la tendència i obtenir prediccions de Y a partir de X.

Equació

$$\hat{y} = b_0 + b_1X$$

b_0 • intercept

Valor predit de Y quan $X = 0$.

Només té sentit substantiu si $X=0$ és interpretable en el context.

b_1 • pendent

Canvi mitjà predit en Y quan X augmenta una unitat.

$b_1 > 0$: recta creixent. $b_1 < 0$: recta decreixent.

$\hat{y}$ («i grega amb barret») és el valor de Y que prediu el model; no és necessàriament el valor real observat.

D'on surten b1 i b0?

Amb una sola X, la pendent es pot obtenir a partir de covariància i variància.

Pendent

$$b1 = \text{cov}(X,Y) / \text{var}(X)$$

Mesura quant canvia $\hat{y}$ per cada unitat addicional de X.

Intercept

$$b0 = \bar{y} - b1\bar{x}$$

Fa que la recta passi pel punt de les mitjanes $(\bar{x}, \bar{y})$.

Recepta

1. Calcula $\bar{x}$ i $\bar{y}$. 2. Calcula $\text{cov}(X,Y)$ i $\text{var}(X)$. 3. $b1=\text{cov}/\text{var}$. 4. $b0=\bar{y}-b1\bar{x}$. 5. Escriu $\hat{y}=b0+b1X$.

Exemple resultat complet

Continuem amb hores de formació (X) i puntuació (Y).

1. Dades prèvies

$$\bar{X} = 6.00$$

$$\bar{Y} = 70.50$$

$$\text{cov}(X,Y) = 28.33$$

$$\text{var}(X) = 7.00$$


2. Pendent

$$b1 = 28.33 / 7.00 = 4.05$$

3. Intercept

$$b0 = 70.50 - 4.05 \cdot 6.00 = 46.21$$

$$\text{RECTA: } \hat{y} = 46.21 + 4.05X$$



La pendent és la peça més important de la recta

No n'hi ha prou amb escriure b_1 : cal traduir-lo al context.

En el nostre exemple

$b_1 = 4.05$

Interpretació: per cada hora addicional de formació, la puntuació predita augmenta aproximadament 4.05 punts.

És una associació estimada per aquestes dades, no una afirmació causal.

Mala interpretació

«La formació provoca exactament aquest augment.»

Bona interpretació

«Segons la recta ajustada, una hora més de X s'associa amb aquest canvi predit en Y.»

De la recta a un valor predit

Substituïm un valor de X dins de l'equació.

Exemple

Recta: $\hat{y} = 46.21 + 4.05X$

Per $X = 6$:

$$\hat{y} = 46.21 + 4.05 \cdot 6 = 70.50$$

Predicció: aproximadament 70.5 punts.

Residual

$$e = y - \hat{y}$$

És la diferència entre el valor observat i el valor predit.

$e > 0$: el punt queda per sobre de la recta.

$e < 0$: queda per sota.

Exemple: predicció $\neq$ observació

Suposem que per $X=7$ observem $Y=74$.

1. Predicció

$$\hat{y} = 46.21 + 4.05 \cdot 7 = 74.55$$

2. Observació

$$y = 74$$

3. Residual

$$e = y - \hat{y} = 74 - 74.55 = -0.55$$

Els residuals mesuren els errors de predicció del model per a les observacions disponibles.

Quina part de la variabilitat de Y recull la recta?

En regressió lineal simple amb intercept, $R^2 = r^2$.

Definició

$$0 \leq R^2 \leq 1$$

$R^2 = 0,80$ significa que el model lineal recull el 80% de la variabilitat observada de Y en aquestes dades.

No significa que X «causi el 80%» de Y.

En regressió simple

$$r = 0.992$$

$$R^2 = r^2 = 0.984$$

→ la recta s'ajusta molt estretament a aquest petit conjunt d'exemple.

Interpolar no és el mateix que extrapolar

Una recta pot donar un número per qualsevol X , però això no vol dir que el número sigui fiable.

INTERPOLACIÓ

Predir dins del rang de X observat.

Ex.: dades entre 2 i 10 hores $\rightarrow$ predir per $X=6$.

Normalment és l'ús més defensable de la recta.

EXTRAPOLACIÓ

Predir fora del rang observat.

Ex.: dades entre 2 i 10 hores $\rightarrow$ predir per $X=30$.

La relació podria canviar fora del rang; cal advertir-ho.

Calcula la recta i interpreta-la

Utilitza les dades següents. Pots aprofitar els càlculs de covariància i variància.

x_i	y_i
2	50
3	56
5	63
7	72
8	76

CALCULA

1. $\bar{x}$ i $\bar{y}$
2. $\text{cov}(X,Y)$ i $\text{var}(X)$
3. $b_1 = \text{cov}/\text{var}(X)$
4. $b_0 = \bar{y} - b_1\bar{x}$
5. Escribeu $\hat{y} = b_0 + b_1X$
6. Prediu Y per $X=6$

INTERPRETA

Què significa b_1 en el context?

La predicció per $X=6$ és interpolació o extrapolació?

El núvol de punts sembla compatible amb una relació lineal?

Correlació no implica causalitat

Una associació pot ser real i útil descriptivament sense demostrar una relació causa–efecte.

Per què?

Pot existir una tercera variable que afecti X i Y.

La direcció causal podria ser inversa.

La relació pot aparèixer per selecció, confusió o atzar.

Per afirmar causalitat cal un disseny i una anàlisi adequats.

Frase segura per a l'informe

«Observem una associació lineal positiva/negativa entre X i Y.»

No escrivim «X provoca Y» només perquè r sigui alt o la regressió sigui significativa.

Com resoldre qualsevol exercici bidimensional

Segueix sempre el mateix ordre.

01

Identifica X i Y i conserva les parelles.

02

Fes el diagrama de dispersió.

03

Mira direcció, forma, intensitat i valors extrems.

04

Calcula covariància i correlació r .

05

Si té sentit lineal, calcula $\hat{y}=b_0+b_1X$.

06

Interpreta b_1 i R^2 .

07

Fes prediccions només amb prudència.

08

Tanca amb una interpretació contextual i evita causalitat no demostrada.

Què heu de saber fer a la pràctica

Excel automatitza càlculs, però heu de saber què significa cada resultat.

Diagrama

Inserir → Dispersió (XY).

X a l'eix horitzontal; Y a l'eix vertical.

Afegir línia de tendència lineal quan es demani.

Mesures

CORREL per obtenir r.

COVARIANCE.P / COVARIANZA.P segons idioma
per a covariància descriptiva.

PENDIENTE/SLOPE i

INTERSECCION.EJE/INTERCEPT per a la recta.

Predicció i ajust

PRONOSTICO.LINEAL / FORECAST.LINEAR per
predir.

Mostrar equació i R^2 al gràfic.

Comprovar sempre que el resultat coincideix
amb la interpretació visual.

Els noms de les funcions poden variar segons l'idioma i la versió d'Excel.

Què fareu a l'activitat interactiva

La pràctica segueix exactament la mateixa seqüència conceptual del tema.

1

Dades aparellades

2

Núvol de punts

3

Covariància i correlació

4

Efecte d'un valor extrem

5

Regressió lineal

6

Predicció i residuals

7

R^2 i extrapolació

8

Informe final

Una bona resposta combina número + gràfic + interpretació

No entregueu només coeficients.

MODEL D'INTERPRETACIÓ

1. Descriu el núvol: direcció, forma i possibles valors extrems.
2. Dona r i interpreta signe/intensitat sense regles mecàniques.
3. Escribeu la recta i interpreta b_1 amb unitats.
4. Dona R^2 com a mesura d'ajust, no de causalitat.
5. Si predius, indica si és interpolació o extrapolació.
6. Tanca amb una frase contextual prudent: associació $\neq$ causalitat.

Miniinforme bidimensional per completar

Context: X = hores de formació; Y = productivitat. Utilitza les dades i completa l'anàlisi.

X	Y
2	41
4	47
5	52
7	57
9	65
10	66

CÀLCULS

r = _____
b0 = _____
b1 = _____
R² = _____
Predicció per X=6: $\hat{y}$ = _____

INTERPRETACIÓ

Direcció del núvol: _____
Pendent en paraules: _____
La predicció és: interpolació / extrapolació
Conclusió sense afirmar causalitat:

De la variància a la covariància

Aquesta diapositiva connecta una idea que ja coneixeu amb la nova mesura bidimensional.

VARIÀNCIA: X AMB ELLA MATEIXA

Mesura com s'allunyen els valors de X de la seva mitjana.

$$\text{var}(X) = \Sigma[(x_i - \bar{x})(x_i - \bar{x})] / N$$

És el mateix que: $\text{var}(X) = \Sigma(x_i - \bar{x})^2 / N$

COVARIÀNCIA: X AMB Y

Ara comparem simultàniament la desviació de X i la desviació de Y.

$$\text{cov}(X,Y) = \Sigma[(x_i - \bar{x})(y_i - \bar{y})] / N$$

Per tant: $\text{var}(X) = \text{cov}(X,X)$

La covariància és, en certa manera, l'extensió de la variància de UNA variable a DUES variables.

ENTENDRE LA COVARIÀNCIA

Per què el signe ens diu si X i Y es mouen juntes?

Per a cada persona multipliquem dues desviacions: $(x_i - \bar{x})$ i $(y_i - \bar{y})$.

$$+ \times + = +$$

X sobre la mitjana · Y sobre la mitjana
mateix sentit

$$- \times - = +$$

X sota la mitjana · Y sota la mitjana
mateix sentit

$$+ \times - = -$$

X sobre la mitjana · Y sota la mitjana
sentit contrari

$$- \times + = -$$

X sota la mitjana · Y sobre la mitjana
sentit contrari

Predominen productes positius → covariància positiva. Predominen productes negatius → covariància negativa.